

MultiTurn-RAG-CustomerService

《中华人民共和国药典》智能问答系统架构梳理

Hermnd-Isabell

2025 年 7 月

目录

- 1. 项目概述
- 2. 已实现功能
- 3. 实现机制详解
- 4. 当前问题与改进方向

1. 项目概述

项目定位

MultiTurn-RAG-CustomerService 是一个基于《中华人民共和国药典》的中文智能问答系统。

Retrieval	Elasticsearch + FAISS 双路检索
Augmented	检索结果作为 LLM 上下文
Generation	OpenAI 兼容 API (默认 DeepSeek)
MultiTurn	支持多轮对话、指代消解、会话上下文

1. 项目概述 — 核心数据流

阶段	处理
文档导入	.docx → ES（整章）→ FAISS（子段落）
用户提问	查询改写 → 意图路由 → 检索决策
检索阶段	ES 精确锁定（主） / FAISS 向量检索（降）
生成阶段	上下文组装 → LLM 流式回答

2. 已实现功能

P0: 基础架构

- **Elasticsearch**: 存储整章原文, doc_id = 药品名
- **FAISS**: 存储子段落向量 (20857 条, 384 维)
- 同一份文档存两份, 目的不同

P1: 意图路由层

- quick_intent_hint: 规则预筛 (闲聊 / 药学 / 模糊)
- classify_pharmacy_query: LLM 二分类 good/bad
- MedicineInfoStandardizer: 提取 target_fields + target_drug

2. 已实现功能 — P2 药品感知重排

全局 FAISS 检索 top-10 后, 双层打分重排:

$$\text{total_score} = \text{drug_score} \times 2 + \text{field_score} \times 1$$

- `_score_result_by_drug_name`: doc_id 与目标药品名匹配
- `_score_result_by_fields`: 段落 title 与 target_fields 匹配
- 匹配小于 3 条时用向量相似度补足

2. 已实现功能 — P2.2 ES 精确锁定

当 target_drug 非空且 ES 中存在时：

- **跳过** 全库 FAISS 盲搜
- 直接 `es.get(index, id=target_drug)` 取整章原文
- `extract_subsections` 切分后按 `target_fields` 过滤
- 匹配字段置顶，其余子段落补足 `top_k`

效果：「川射干的性状」直接命中【性状】段落，零漂移。

2. 已实现功能 — P4.1 查询改写

解决多轮对话中的**指代消解**问题。

规则预筛

- 已含药名 / 无指代词 → 跳过改写，节省 LLM 调用

指代词集合 {他, 她, 它, 这个药, 该药, 刚才, 上面, 之前, ...}

LLM 改写

- 结合最近 3 轮 history，消除指代词

Q1: 川射干的性状是什么？

Q2: 他的副作用是什么？

改写后: 川射干的副作用是什么？

2. 已实现功能 — P4.2 / P4.3

P4.2: 上下文感知检索

- retrieve_with_context: 基础检索 top-15 + context_drug 硬过滤
- 匹配药品的结果置顶, 不足时补足
- 改写层的**双保险**: 即使 LLM 改写失败, 检索层仍能硬约束

P4.3: 会话事实缓存

模块级 _session_facts 字典 (Gradio 进程隔离 = 会话隔离):

- primary_drug: 当前会话主要讨论药品
- queried_fields: 已查询字段集合 (去重)
- last_intent: 上一轮意图
- drug_history: 会话中所有药品 (按时间顺序)

2. 已实现功能 — 测试覆盖

测试文件	数量	覆盖范围
test_config.py	17	配置读取 / 默认值
test_embed.py	48	嵌入 / 检索 / 字段提取
test_webrun.py	45	slow_echo 分支 / 改写 / 缓存
test_drug_aware_rerank.py	18	药品名打分 / 提取 / ES 确认

总计：128 个测试全部通过

3. 实现机制详解

检索决策流程

条件	路径
target_drug 非空 且 drug_exists	主路径: ES 精确锁定
target_drug 为空 且 session_drug 非空	降级: retrieve_with_context
target_drug 为空 且 session_drug 为空	降级: FAISS 全库 top-3
全库未命中目标药品	兜底: retrieve_vector_and_text_for_drug

关键模块

- config.py — 全局配置单例 (运行时热更新)
- embed.py — 向量 / ES / LLM 工具函数
- webrun.py — Gradio UI + slow_echo 主流程
- tests/ — pytest + MagicMock 全覆盖

4. 当前问题与改进方向

结构性问题

- **向量语义漂移**: FAISS 只编码子段落内容, 不含药品名 → “川射干的性状” 编码后失去 “川射干” 信号
- **切分规则硬编码**: 依赖 12pt 字体 + 固定正则 → 非标准 .docx 无法正确分章
- **模型不可切换**: Sentence-Transformer 固定加载

工程性问题

- **LLM 依赖**: 改写/分类/提取均走外部 API → 延迟高、成本高
- **会话状态易失**: `_session_facts` 模块级变量, 进程重启即丢失
- **无对话持久化**: 没有数据库记录历史问答
- **Windows-only**: 启动脚本为 .bat, 跨平台性差
- **无权限管理**: 配置页密码明文, 无用户隔离

4. 改进方向

短期

- 向量库编码时 prepend 药品名 ([川射干] 本品为...)
- 引入本地小模型做意图分类 (减少 LLM 调用)
- 添加 SQLite 对话历史持久化

中长期

- 支持多药品对比查询
- 动态 field_list 扩展 (用户自定义字段)
- 跨平台启动脚本 (sh + Docker)
- 引入重排序模型 (Cross-Encoder) 替代规则打分
- 向量库支持增量更新 (无需全量重建)

谢谢！

GitHub: <https://github.com/Hermnd-Isabell/MultiTurn-RAG-CustomerService>